

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



BÁO CÁO THỰC TẬP CƠ SỞ

ĐỀ TÀI:

**HỆ THỐNG THÔNG MINH HỖ TRỢ HỌC TẬP: TỰ
ĐỘNG TÓM TẮT VÀ SINH CÂU HỎI TỪ TÀI LIỆU
HỌC TẬP**

Giảng viên hướng dẫn	: Ths. Kim Ngọc Bách
Sinh viên thực hiện	: Nguyễn Tiến Dũng
Mã sinh viên	: B23DCVT107
Lớp	: D23CQCE02-B

Hà Nội – 2026

MỤC LỤC

1. GIỚI THIỆU	3
1.1. Lý do chọn đề tài	3
1.2. Mục tiêu	3
1.3. Phạm vi	3
2. CƠ SỞ LÝ THUYẾT	3
2.1. Xử lý ngôn ngữ tự nhiên (NLP)	3
2.2. Nhận dạng ký tự quang học (OCR)	3
2.3. Tóm tắt văn bản	3
2.4. Thuật toán TextRank	4
2.5. Sinh câu hỏi tự động (Question Generation)	4
3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	4
3.1. Yêu cầu chức năng	4
3.2. Kiến trúc tổng thể	4
3.3. Thiết kế cơ sở dữ liệu	4
3.4. Luồng xử lý chính	5
4. CÔNG NGHỆ SỬ DỤNG	5
5. KẾT QUẢ CÀI ĐẶT	5
5.1. Các chức năng đã hoàn thành	5
5.2. Giao diện ứng dụng	6
6. ĐÁNH GIÁ	6
6.1. So sánh các phương pháp tóm tắt	6
6.2. Hạn chế OCR tiếng Việt và giải pháp	6
7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	6
8. TÀI LIỆU THAM KHẢO	7

1. GIỚI THIỆU

1.1. Lý do chọn đề tài

Sinh viên ngày nay tiếp nhận tài liệu học tập từ nhiều nguồn và nhiều định dạng khác nhau: bản PDF được quét, ảnh chụp slide bằng điện thoại, file Word, PowerPoint. Việc tổng hợp, gộp lại nội dung và tạo đề cương ôn tập tiêu tốn nhiều thời gian. Các công cụ hiện có thường chỉ xử lý một loại đầu vào hoặc một tác vụ riêng lẻ.

Đề tài xây dựng một hệ thống thống nhất: số hóa tài liệu đa định dạng bằng OCR, tóm tắt nội dung, trích xuất từ khoá và tự động sinh câu hỏi/flashcard phục vụ ôn tập, qua đó giúp người học nắm ý chính và ghi nhớ hiệu quả hơn.

1.2. Mục tiêu

- Nhận và bóc tách văn bản từ nhiều định dạng: PDF, ảnh, Word, PowerPoint, Excel, TXT.
- Làm sạch dữ liệu, tách từ/câu cho tiếng Việt và tiếng Anh.
- Trích xuất từ khoá và tóm tắt theo số câu hoặc theo tỷ lệ phần trăm.
- Tự động sinh câu hỏi và flashcard, hỗ trợ ôn tập theo lặp lại ngắt quãng.
- Lưu trữ và xuất kết quả ra văn bản; so sánh, đánh giá các phương pháp tóm tắt.

1.3. Phạm vi

Sản phẩm là một ứng dụng máy tính (desktop) chạy cục bộ, hướng tới tài liệu học thuật ngắn và trung bình bằng tiếng Việt hoặc tiếng Anh. Hệ thống ưu tiên các phương pháp tóm tắt trích xuất (extractive) làm nền tảng, có tích hợp tóm tắt sinh (abstractive) và sinh câu hỏi nâng cao như tùy chọn.

2. CƠ SỞ LÝ THUYẾT

2.1. Xử lý ngôn ngữ tự nhiên (NLP)

Xử lý ngôn ngữ tự nhiên là tập hợp các kỹ thuật tính toán nhằm phân tích và biểu diễn văn bản ngôn ngữ tự nhiên ở nhiều cấp độ, hướng tới khả năng xử lý ngôn ngữ gần với con người. Một số ứng dụng tiêu biểu gồm dịch máy, lọc thư rác, trợ lý ảo, tóm tắt văn bản và phân tích cảm xúc.

2.2. Nhận dạng ký tự quang học (OCR)

OCR là quá trình chuyển đổi hình ảnh chứa văn bản (tài liệu quét, ảnh chụp) thành văn bản được mã hóa mà máy tính xử lý được. Quy trình OCR thường gồm: thu nhận ảnh, tiền xử lý, phát hiện vùng chữ, nhận dạng và hậu xử lý.

2.3. Tóm tắt văn bản

Có hai hướng chính: (i) Tóm tắt trích xuất (extractive) — chọn lọc các câu quan trọng từ văn bản gốc (Luhn, 1958); (ii) Tóm tắt sinh (abstractive) — hiểu nội dung và diễn đạt lại bằng từ ngữ mới (Rush và cộng sự, 2015).

2.4. Thuật toán TextRank

TextRank (Mihalcea và Tarau, 2004) là thuật toán xếp hạng văn bản dựa trên đồ thị. Các bước: tách câu; xây dựng ma trận tương đồng giữa các câu (dùng TF-IDF/độ tương đồng cosine); biểu diễn mỗi câu là một đỉnh với trọng số cạnh là độ tương đồng; chạy PageRank để cho điểm; chọn các câu điểm cao nhất làm bản tóm tắt.

2.5. Sinh câu hỏi tự động (Question Generation)

Sinh câu hỏi tự động là tác vụ tạo câu hỏi từ văn bản đầu vào phục vụ đánh giá kiến thức (Heilman và Smith, 2010). Hai hướng phổ biến: tiếp cận dựa trên luật/mẫu câu (Mitkov và Ha, 2003) và tiếp cận dựa trên mô hình transformer như T5/BART (Lopez và cộng sự, 2021).

3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1. Yêu cầu chức năng

- Tiếp nhận đa định dạng đầu vào: PDF, ảnh, Word, PowerPoint, Excel, TXT.
- Nhận diện chữ, làm sạch dữ liệu, tách từ tiếng Việt/tiếng Anh.
- Xác định từ khoá; tóm tắt theo số câu hoặc theo tỷ lệ phần trăm.
- Tự động sinh câu hỏi/flashcard; quản lý bộ thẻ (deck) và ôn tập.
- Lưu trữ lịch sử, xuất kết quả ra tệp văn bản; so sánh các phương pháp.

3.2. Kiến trúc tổng thể

Hệ thống được chia thành các module rõ ràng, giao tiếp qua cơ sở dữ liệu SQLite:

Module	Vai trò
app.py	Giao diện người dùng (customtkinter) với 5 màn hình: Scan, So sánh, Lịch sử, Flashcard, Ôn tập.
Paddle_ocr_scanner.py	Bóc tách văn bản đa định dạng; nhiều engine OCR (PaddleOCR, EasyOCR, Tesseract) qua một factory chọn engine theo ngôn ngữ; hàm so sánh OCR.
summarizer.py	Tiền xử lý, tách từ tiếng Việt (underthesea), trích xuất từ khoá (KeyBERT/RAKE), các thuật toán tóm tắt, sinh câu hỏi và so sánh phương pháp.
database.py	Lưu trữ SQLite: lịch sử scan, tóm tắt, từ khoá, flashcard và nhật ký ôn tập; sinh flashcard tự động.

3.3. Thiết kế cơ sở dữ liệu

Dữ liệu được lưu trong SQLite (tệp smartnote.db) với các bảng chính:

Bảng	Mô tả
scans	Thông tin tài liệu đã scan: tên file, loại, ngôn ngữ, văn bản gốc, thời điểm, số ký tự.

summaries	Bản tóm tắt theo từng thuật toán cho mỗi lần scan.
keywords	Danh sách từ khoá trích xuất.
flashcards	Thẻ câu hỏi/đáp án: mặt trước, mặt sau, gợi ý, bộ thẻ (deck), độ khó.
review_log	Nhật ký ôn tập phục vụ lặp lại ngắt quãng (đúng/sai/bỏ qua, lần ôn kế tiếp).

3.4. Luồng xử lý chính

- Người dùng chọn tệp (hoặc dán văn bản) và cấu hình ngôn ngữ, engine OCR, chế độ tóm tắt.
- Hệ thống OCR/đọc văn bản, làm sạch và tách từ.
- Trích xuất từ khoá, tạo bản tóm tắt và lưu vào cơ sở dữ liệu.
- Tự động sinh flashcard/câu hỏi; người dùng ôn tập và tra cứu lại trong Lịch sử.

4. CÔNG NGHỆ SỬ DỤNG

Nhóm	Thư viện / công cụ
Ngôn ngữ & giao diện	Python 3.x, customtkinter (giao diện desktop).
OCR	PaddleOCR; bổ sung EasyOCR và Tesseract cho tiếng Việt; PyMuPDF, python-docx, python-pptx, openpyxl, Pillow để đọc đa định dạng.
NLP / tóm tắt	underthesea (tách từ tiếng Việt), KeyBERT + sentence-transformers, RAKE, sumy (LSA, TextRank), NetworkX + scikit-learn (TextRank thuần).
Tóm tắt & QG sinh	Google Gemini (google-genai) cho tóm tắt abstractive và sinh câu hỏi.
Lưu trữ	SQLite3 (tích hợp sẵn trong Python).

5. KẾT QUẢ CÀI ĐẶT

5.1. Các chức năng đã hoàn thành

- Bóc tách văn bản đa định dạng (PDF, ảnh, Word, PowerPoint, Excel, TXT).
- Trích xuất từ khoá (KeyBERT, có hỗ trợ tách từ tiếng Việt) và tóm tắt theo số câu hoặc phần trăm.
- Nhiều thuật toán tóm tắt: LSA, TextRank (sumy), NetworkX TextRank (PageRank + TF-IDF cosine), TextTeaser, KeyBERT, Voting ensemble và Gemini (abstractive).
- Sinh câu hỏi tự động theo luật: định nghĩa-trong-ngữ-cảnh và điền khuyết (cloze); tùy chọn sinh câu hỏi bằng Gemini.
- Quản lý flashcard theo bộ thẻ (đổi tên, xóa bộ) và ôn tập theo lặp lại ngắt quãng.

- Lưu lịch sử, xuất kết quả ra tệp .txt và màn hình so sánh các phương pháp tóm tắt.

5.2. Giao diện ứng dụng

Ứng dụng gồm 5 màn hình: (1) Scan — chọn nguồn, cấu hình và chạy OCR + tóm tắt; (2) So sánh — đối chiếu các phương pháp tóm tắt kèm chỉ số; (3) Lịch sử — tra cứu, xuất, xoá tài liệu đã xử lý; (4) Flashcard — quản lý bộ thẻ và thẻ; (5) Ôn tập — học theo thẻ và ghi nhận kết quả.

6. ĐÁNH GIÁ

6.1. So sánh các phương pháp tóm tắt

Hệ thống cung cấp bộ chỉ số không cần bản tham chiếu để so sánh: tỉ lệ nén, số câu, thời gian chạy và độ phủ từ khoá. Bảng dưới là kết quả minh hoạ trên một văn bản mẫu (tóm tắt 2 câu):

Phương pháp	Nén	Số câu	Thời gian	Phủ từ khoá
NetworkX TextRank	22.1%	2	2.02 s	0%
TextRank (sumy)	28.4%	2	0.61 s	33%
LSA	25.6%	2	0.18 s	33%
TextTeaser	28.8%	2	0.05 s	17%
KeyBERT	28.4%	2	0.12 s	33%
Voting ensemble	28.4%	2	0.23 s	33%

Nhận xét: các phương pháp cho độ nén tương đương; phương pháp tổ hợp (voting) và các phương pháp dựa trên từ khoá đạt độ phủ từ khoá cao hơn. Cần lưu ý chỉ số phủ từ khoá chỉ là proxy chất lượng, không thay thế đánh giá ROUGE có bản tham chiếu.

6.2. Hạn chế OCR tiếng Việt và giải pháp

PaddleOCR phiên bản 3.x ánh xạ ngôn ngữ "vi" sang mô hình "latin" dùng chung, vốn không phủ đầy đủ ký tự tiếng Việt; do đó văn bản tiếng Việt bị rưng dầu (ví dụ "KỶ NĂNG TẠO LẬP VĂN" bị nhận thành "K NNG TO LP VN"). Giải pháp đã áp dụng: bổ sung hai engine có hỗ trợ tiếng Việt là EasyOCR và Tesseract, cho phép chọn engine theo ngôn ngữ; đồng thời tách từ tiếng Việt bằng underthesea và lọc hư từ để cải thiện chất lượng từ khoá.

7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Đề tài đã xây dựng được một hệ thống hoàn chỉnh, đáp ứng các yêu cầu đặt ra: xử lý tài liệu đa định dạng, tóm tắt theo nhiều phương pháp, sinh câu hỏi/flashcard và lưu trữ, đánh giá. Hệ thống bám sát cơ sở lý thuyết về NLP, OCR, tóm tắt văn bản và sinh câu hỏi.

Hướng phát triển tiếp theo:

- Tích hợp đánh giá ROUGE với bản tóm tắt tham chiếu và chế độ đánh giá hàng loạt.
- Bổ sung sinh câu hỏi bằng mô hình transformer chạy ngoại tuyến (T5/ViT5).
- So sánh định lượng các engine OCR (PaddleOCR, EasyOCR, Tesseract) trên tập dữ liệu tiếng Việt.
- Hoàn thiện giao diện và trải nghiệm người dùng, tối ưu hiệu năng tải mô hình.

8. TÀI LIỆU THAM KHẢO

- [1] Baidu. PaddleOCR: Awesome multilingual OCR toolkits based on PaddlePaddle. GitHub, 2020.
- [2] Du, Y. và cộng sự. PP-OCR: A practical ultra lightweight OCR system. arXiv:2009.09941, 2020.
- [3] Hagberg, A. và cộng sự. Exploring network structure, dynamics, and function using NetworkX. SciPy, 2008.
- [4] Heilman, M. và Smith, N. A. Good question! Statistical ranking for question generation. NAACL, 2010.
- [5] Luhn, H. P. The automatic creation of literature abstracts. IBM Journal, 1958.
- [6] Mihalcea, R. và Tarau, P. TextRank: Bringing order into text. EMNLP, 2004.
- [7] Mitkov, R. và Ha, L. A. Computer-aided generation of multiple-choice tests. HLT-NAACL Workshop, 2003.
- [8] Nguyen, V. Underthesea: A Vietnamese NLP Toolkit. GitHub, 2019.
- [9] Pedregosa, F. và cộng sự. Scikit-learn: Machine learning in Python. JMLR, 2011.
- [10] Rush, A. M. và cộng sự. A neural attention model for abstractive sentence summarization. EMNLP, 2015.
- [11] JaidedAI. EasyOCR. GitHub, 2020.
- [12] Smith, R. An overview of the Tesseract OCR engine. ICDAR, 2007.