HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

ĐỀ CƯƠNG THỰC TẬP CƠ SỞ

Đề Tài: Hệ thống thông minh hỗ trợ học tập: Tự động tóm tắt và sinh câu hỏi từ tài liệu học tập

Giảng viên hướng dẫn	**: Ths. Kim Ngọc Bách**
Sinh viên thực hiện	**: Nguyễn Tiến Dũng**
Mã sinh viên	**: B23DCVT107**
Lớp	**: D23CQCE02-B**

Hà Nội – 2026

MỤC LỤC

1.Giới thiệu dự án 3
1.1 Lý do chọn đề tài 3
1.2. Ý nghĩa thực tiễn 3
1.3. Giá trị học thuật 3
2.Cơ sở lý thuyết và công nghệ 3
2.1. Cơ sở lý thuyết 3
2.1.1 XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NLP) 3
2.1.2 Nhận dạng ký tự quang học (OCR) 4
2.1.5 Sinh câu hỏi tự động (Question Generation) 6
2.2 Công nghệ sử dụng 6
3.Phân tích yêu cầu dự án 6
4. Kế hoạch xây dựng và triển khai 7
References 8

1.Giới thiệu dự án

1.1 Lý do chọn đề tài

- Nhu cầu thực tế cấp thiết

- Sinh viên nhận tài liệu từ **nhiều nguồn khác nhau**: PDF scan, slide chụp bằng điện thoại, file Word, PowerPoint
- Mất **hàng giờ để tổng hợp, gõ lại, tạo đề cương** thay vì tập trung học
- Các công cụ hiện tại chỉ xử lý được 1 loại đầu vào hoặc 1 tác vụ riêng lẻ

1.2. Ý nghĩa thực tiễn

- **Tiết kiệm thời gian** tổng hợp tài liệu
- **Học hiệu quả hơn:** Tóm tắt nắm ý chính, câu hỏi tự kiểm tra, flashcard ghi nhớ lâu
- **Xử lý mọi định dạng:** Từ slide chụp bằng điện thoại đến giáo trình PDF
- **Soạn câu hỏi trắc nghiệm nhanh** từ bài giảng
- **Hỗ trợ sinh viên yếu** bằng tài liệu tóm tắt
- **Bảo tồn tài liệu:** Số hóa sách cũ, tài liệu quý hiếm

1.3. Giá trị học thuật

- **So sánh đánh giá các phương pháp OCR** trên dữ liệu tiếng Việt (PaddleOCR, Tesseract, EasyOCR)
- **Nghiên cứu mô hình tóm tắt văn bản tiếng Việt** (word2vec) trên tài liệu học thuật
- **Đề xuất pipeline tối ưu** xử lý tài liệu học tập đa định dạng

Ứng dụng AI vào giáo dục (AIEd)

- Đóng góp vào lĩnh vực **xử lý ngôn ngữ tự nhiên cho tiếng Việt**
- **Bài toán sinh câu hỏi tự động**

2.Cơ sở lý thuyết và công nghệ

2.1. Cơ sở lý thuyết

2.1.1 XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NLP)

- Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing – NLP) là một tập hợp các kỹ thuật tính toán được xây dựng dựa trên cơ sở lý thuyết, nhằm phân tích và biểu diễn các văn bản ngôn ngữ tự nhiên ở một hoặc nhiều cấp độ phân tích ngôn ngữ, với mục đích đạt được khả năng xử lý ngôn ngữ giống như con người cho nhiều nhiệm vụ hoặc ứng dụng khác nhau.

- Mục tiêu của NLP là "đạt được khả năng xử lý ngôn ngữ giống như con người". Việc lựa chọn từ "xử lý" (processing) là hoàn toàn có chủ ý và không nên được thay thế bằng từ "hiểu" (understanding).

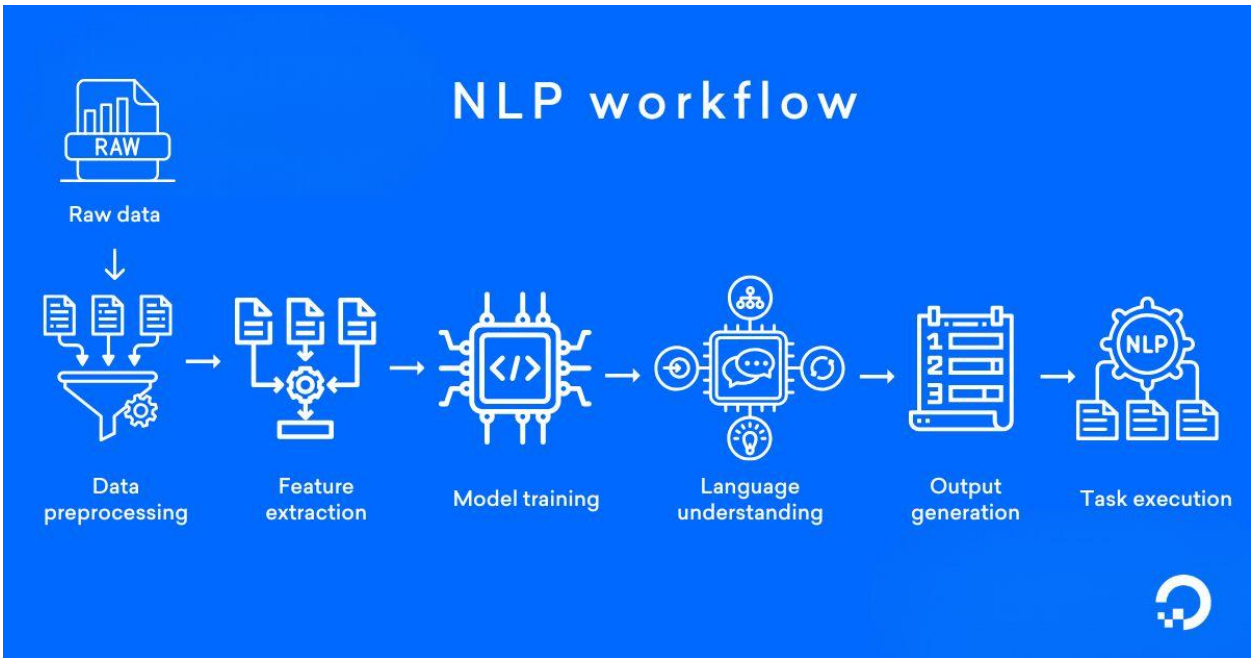

- **Một số ứng dụng cơ bản nhất của NLP bao gồm:**
    - Bản dịch ngôn ngữ thời gian thực
    - Bộ lọc thư rác trong dịch vụ email
    - Trợ lý giọng nói và chatbot
    - Tóm tắt văn bản
    - Tính năng tự động sửa
    - Phân tích cảm xúc

2.1.2 Nhận dạng ký tự quang học (OCR)

- Nhận dạng ký tự quang học (Optical Character Recognition – OCR), còn gọi là bộ đọc ký tự quang học, là quá trình chuyển đổi bằng phương tiện điện tử hoặc cơ học các hình ảnh chứa văn bản đánh máy, viết tay hoặc in ấn thành văn bản được mã hóa mà máy tính có thể xử lý.
- Nguồn hình ảnh có thể là tài liệu được quét (scan), ảnh chụp tài liệu, ảnh chụp trong thực tế (ví dụ như chữ trên biển báo hoặc bảng quảng cáo trong một bức ảnh phong cảnh) hoặc văn bản phụ đề được chèn lên hình ảnh (ví dụ như trong một chương trình truyền hình).

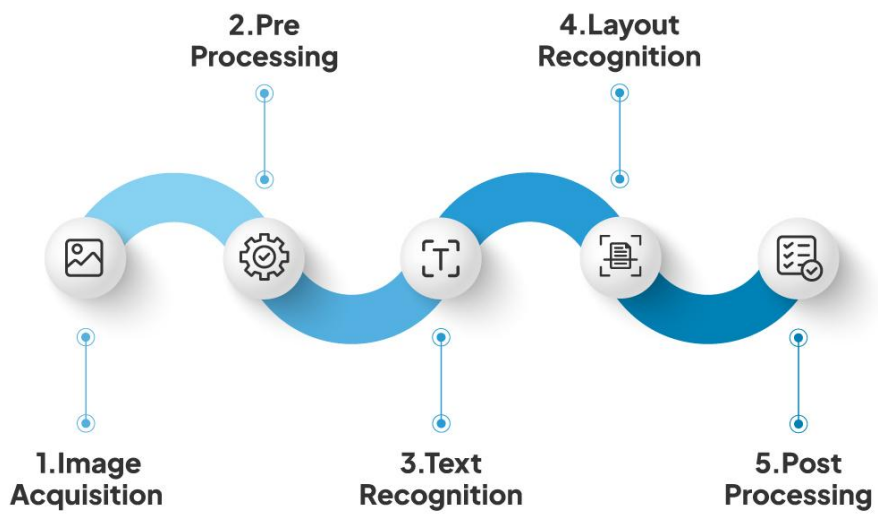

- Các công cụ OCR đã được phát triển thành những ứng dụng phần mềm chuyên biệt cho nhiều lĩnh vực khác nhau như hóa đơn bán lẻ, hóa đơn tài chính, séc ngân hàng và các tài liệu thanh toán trong lĩnh vực pháp lý.

2.1.3 Tóm tắt văn bản (Text Summarization)

- Tóm tắt văn bản là quá trình tạo ra một phiên bản cô đọng của văn bản gốc, giữ lại các thông tin quan trọng nhất. Có hai phương pháp chính:
  - Tóm tắt trích xuất (Extractive Summarization): Chọn lọc các câu, đoạn quan trọng từ văn bản gốc để ghép thành bản tóm tắt (Luhn 1958).
  - Tóm tắt sinh (Abstractive Summarization): Hiểu nội dung và diễn đạt lại bằng từ ngữ mới, giống như con người tóm tắt (Rush et al. 2015).

2.1.4 Thuật toán TextRank

- TextRank là thuật toán xếp hạng văn bản dựa trên đồ thị, được Mihalcea và Tarau (2004) đề xuất. Các bước thực hiện:

  1. Tách câu: Chia văn bản thành các câu riêng biệt
  2. Xây dựng ma trận tương đồng:Tính độ tương đồng giữa các câu dựa trên TF-I DF hoặc các đặc trưng khác
  3. Xây dựng đồ thị:Mỗi câu là một đỉnh, trọng số cạnh là độ tương đồng
  4. Tính PageRank: Sử dụng thuật toán PageRank để xếp hạng các câu
  5. Chọn câu: Lấy các câu có điểm cao nhất làm tóm tắt
    - Công thức tính độ tương đồng cosine:

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}},$$

2.1.5 Sinh câu hỏi tự động (Question Generation)

- Sinh câu hỏi tự động (Automatic Question Generation - QG) là tác vụ NLP tạo ra câu hỏi từ văn bản đầu vào, phục vụ mục đích đánh giá kiến thức (Heilman và Smith 2010).
- Các phương pháp phổ biến:

  - Rule-based approach: Sử dụng các mẫu câu (template) và quy tắc ngữ pháp (Mitkov và Ha 2003)

  - Transformer-based approach: Sử dụng các mô hình như T5, BART được fine-tune cho tác vụ sinh câu hỏi (Lopez et al. 2021)

2.2 Công nghệ sử dụng

-Ngôn ngữ lập trình: Python 3.10+
-Các thư viện chính: +PyPDF2
+pdfplumber
+python-docx
+python-pptx
+Pillow
+Streamlit
+NumPy
+Pandas
-Công cụ OCR: PaddleOCR
-Thư viện NLP: +Underthesea
+Rake-NLTK
+KeyBERT
+Scikit-learn
+NetworkX
-Lưu trữ dữ liệu: SQLite3

3.Phân tích yêu cầu dự án

Dự án cần đạt được các yêu cầu sau:

- Hệ thống cần có khả năng nhận đa dạng loại file như PDF, Word, PPT, ảnh, TXT
- Có khả năng nhận diện chữ ở mức tốt, làm sạch dữ liệu đầu vào, tách từ hoặc câu tiếng Việt hoặc tiếng Anh
- Có khả năng xác định từ khoá và tóm tắt văn bản theo tỷ lệ phần trăm hoặc số câu
- Lưu trữ tài liệu / xuất tài liệu dưới dạng text

4. Kế hoạch xây dựng và triển khai

Cộng việc thực hiện	Quãng thời gian
Phân tích và thiết kế: phân tích, tìm hiểu các công nghệ, thiết lập xử lý file đa định dạng	1 tuần
Xây dựng phần xử lý văn bản tiếng Việt	1 tuần
Xây dựng thuật toán TextRank, trích xuất từ khoá nhằm tóm tắt văn bản	1 tuần
Xây dựng tạo câu hỏi và flashcard ghi nhớ	1 tuần
Xây dựng Database SQLite để lưu trữ dữ liệu	1 tuần
Hoàn thiện UI, kết nối các module	1 tuần
Kiểm thử, sửa lỗi, hoàn thiện và làm báo cáo	1 tuần

References

Baidu. "PaddleOCR: Awesome multilingual OCR toolkits based on PaddlePaddle." *GitHub repository*, 2020, github.com/PaddlePaddle/PaddleOCR.

Du, Yuning, et al. "PP-OCR: A practical ultra lightweight OCR system." *arXiv preprint arXiv:2009.09941*, 2020.

Hagberg, Aric, et al. "Exploring network structure, dynamics, and function using NetworkX." *Proceedings of the 7th Python in Science Conference*, 2008, pp. 11-15.

Heilman, Michael, và Noah A. Smith. "Good question! statistical ranking for question generation." *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*, 2010, pp. 609-617.

Liddy, Elizabeth D. "Natural language processing." *Encyclopedia of Library and Information Science*, 2nd ed., Marcel Dekker, 2001.

Luhn, Hans Peter. "The automatic creation of literature abstracts." *IBM Journal of research and development*, vol. 2, no. 2, 1958, pp. 159-165.

Mihalcea, Rada, và Paul Tarau. "TextRank: Bringing order into text." *Proceedings of the 2004 conference on empirical methods in natural language processing*, 2004, pp. 404-411.

Mitkov, Ruslan, và Le An Ha. "Computer-aided generation of multiple-choice tests." *Proceedings of the HLT-NAACL 2003 Workshop on Building Educational Applications Using Natural Language Processing*, 2003, pp. 17-22.

Nguyen, Vu. "Underthesea: A Vietnamese NLP Toolkit." *GitHub repository*, 2019, github.com/undertheseanlp/underthesea.

Pedregosa, Fabian, et al. "Scikit-learn: Machine learning in Python." *Journal of machine learning research*, vol. 12, 2011, pp. 2825-2830.

Rush, Alexander M., et al. "A neural attention model for abstractive sentence summarization." *Proceedings of the 2015 conference on empirical methods in natural language processing*, 2015, pp. 379-389.